




Projekt 1, SAD 2026L

Ogólne zasady

- (A) W ramach pierwszego projektu zaliczeniowego należy przygotować analizę statystyczną wybranego przez siebie zbioru danych.
- (B) Analizę tę należy przedstawić w formie prezentacji na zajęciach laboratoryjnych; termin prezentacji zgodny z poniższą tabelką:

gr. 6, 7 (pon.)	gr. 1 (czw.)	gr. 3, 5 (pt.)
11 maja	7 maja	6 maja (śr.!)

- (C) Maksymalny czas trwania prezentacji to 10 minut.
- (D) Analizę (oraz jej prezentację) należy przedstawić w 2-osobowych zespołach. Utworzenie zespołu 3-osobowego jest możliwe, wymaga jednak zgody prowadzącego laboratorium (i raczej powinno być podyktowane bezskutecznymi próbami utworzenia zespołu dwuosobowego).
Członkowie zespołu mogą pochodzić z różnych grup laboratoryjnych, należy o tym wówczas do 26 kwietnia powiadomić o tym prowadzących te grupy, którzy ustalą wówczas termin prezentacji.
- (E) Prezentacja ma być wygenerowana z pliku w formacie **RMarkdown** przy pomocy dostępnego w języku **R** pakietu **rmarkdown**. Zapewne najwygodniejsze do tego celu będą narzędzia wbudowane w edytor *RStudio*, które pozwalają na wygenerowanie prezentacji właśnie z tego poziomu (podstawowe informacje na ten temat można znaleźć np. tutaj).
- (F) Kod **R** generujący merytoryczny wkład do powyższej prezentacji (np. statystyki, wyniki testów, wykresy...) powinien być **odkryty** na slajdach. W przypadku grafik można pominąć fragmenty odpowiadające za ich estetyczne dopracowanie.
- (G) Do końca dnia **poprzedzającego dzień prezentacji** należy wysłać prowadzącemu laboratorium zaprezentowane slajdy w formacie **pdf** lub **html**, link do danych, których dotyczyła prezentacja, jak również generujący prezentację kod **Rmarkdown**. Sam kod nie podlega ocenie, warto jednak zadbać o jego czytelność.
- (H) Za wykonaną analizę będzie można otrzymać co najwyżej 15 punktów. Liczba punktów jest przyznawana na podstawie przedstawionej prezentacji i mają na nią wpływ zarówno kwestie merytoryczne, jak i estetyczne (np. staranność przygotowanych grafik).

Wymagania dotyczące zbioru danych

Dane, na których oparta zostanie analiza, powinny być publicznie dostępne. W Internecie istnieje oczywiście mnóstwo stron, na których takie dane można znaleźć, kilka przykładów poniżej

- kaggle.com
- ourworldindata.org
- data.worldbank.org
- stat.gov.pl

Przydatna może być również dedykowana wyszukiwarka Google.

Minimalne wymagania, które powinien spełniać ów zbiór danych, to:

- co najmniej dwie *zmienne ilościowe* (np. wzrost, cena, stężenie substancji...),
- co najmniej dwie *zmienne jakościowe*, przyjmujące od 2 do 20 możliwych wartości (np. kolor oczu, płeć, informacja o podjętym leczeniu...). Jeśli zmienne jakościowe przyjmują więcej wartości, należy te wartości pogrupować w maksymalnie 20 zbliżonych grup (informację o zastosowanym grupowaniu należy przedstawić w prezentacji).
- co najmniej 100 obserwacji.

Zawartość analizy

W kwestii zawartości merytorycznej przedstawionej analizy ma miejsce dość duża swoboda. Analiza ma mieć statystyczny charakter i powinny się pojawić w niej co najmniej 3 elementy teoretyczne i co najmniej 3 elementy graficzne spośród niżej wymienionych:

- *teoretyczne*: estymacja parametrów rozkładu, przedziały ufności dla parametrów, testy równości parametrów rozkładu, testy zgodności z rozkładem, testy niezależności, regresja liniowa (weryfikacja założeń, dopasowanie modelu, testy istotności współczynników), korelacje między zmiennymi
- *graficzne*: histogramy, dystrybuanty empiryczne, wykresy wiolinowe, wykresy pudełkowe, mapy ciepła (*heatmaps*), wykresy dopasowanej zależności między dwiema zmiennymi (liniowej, wielomianowej, etc.), wykresy diagnostyczne dla modeli liniowych

Idealna prezentacja powinna być spójną opowieścią o wybranym zbiorze danych, w której niebanalne pytania i hipotezy dotyczące badanych zjawisk są weryfikowane przy pomocy opisanych wyżej (lub podobnych) metod graficznych i analitycznych.

Poniżej znajdują się przykłady zastosowania niektórych z wyżej wymienionych haseł w analizie:

- (a) (*ten punkt powinien wystąpić w każdej prezentacji*) Podstawowe omówienie zbioru danych. Czym są występujące w nim zmienne (a przynajmniej te, którym będziemy przyglądać się w prezentacji), skąd zostały wzięte dane, liczba obserwacji, liczba zmiennych, liczba brakujących obserwacji (jeśli dotyczy) i jak te brakujące obserwacje zostały potraktowane w dalszej analizie. Dla zmiennych występujących w prezentacji należy wyznaczyć ich podstawowe statystyki (np. dla ciągłych: minimum, maksimum, medianę, średnią arytmetyczną, odchylenie standardowe; dla jakościowych: licznosci poszczególnych grup).
- (b) Wybrać jedną ze zmiennych jakościowych U i jedną ze zmiennych ilościowych X , a następnie przy użyciu wykresu (wykres pudełkowy lub wiolinowy) porównać rozkłady zmiennej X w podziale na możliwe wartości zmiennej U . Na wykresie zaznaczyć średnią i/lub medianę zmiennej X w wybranych grupach.
- (c) Wybrać dwie zmienne ciągłe i przedstawić na wykresie kropkowym zależność między nimi, wraz z zaznaczoną prostą regresji liniowej (z wyrazem wolnym). Sprawdzić, czy spełnione są założenia modelu regresji liniowej przy pomocy wykresów diagnostycznych. Rozważyć dopasowanie bardziej skomplikowanej funkcji (np. wielomianu stopnia większego od 1).
- (d) Do wybranej zmiennej ciągłej (lub pewnej jej transformacji, np. logarytmu) dopasować rozkład prawdopodobieństwa, z którego mogła być losowana. Wybrać rodzinę rozkładów (normalne/wykładnicze/...) i wybraną przez siebie metodą (momentów/największej wiarygodności) dopasować parametry tego rozkładu. Należy narysować wykres kwantylowy (QQ-plot) dla tego dopasowania oraz dystrybuantę empiryczną z dopasowaną dystrybuantą. Przedstawić wynik testu Kołmogorowa-Smirnowa dla hipotezy o pochodzeniu z dopasowanego rozkładu. (Tu i przy innych testach należy rozumieć, jak interpretować uzyskane p-wartości!)
- (e) Dla wybranej(-ych) wartości zmiennej jakościowej podać przedział ufności Wilsona dla udziału tej zmiennej w całej populacji.

- (f) Wykonać regresję liniową jednej ze zmiennych ciągłych względem co najmniej dwóch pozostałych zmiennych. Jeśli wśród zmiennych objaśniających znajduje się zmienna jakościowa, powinna być odpowiednio potraktowana (tzn. skonwertowana do klasy **factor**). Przedstawić dopasowane współczynniki, jak również błąd średniokwadratowy (tzn. estymator σ^2). Sprawdzić, czy wszystkie współczynniki są statystycznie istotne.

W prezentacji mogą pojawić się techniki statystyki matematycznej/wizualizacji danych, które nie były omówione na wykładzie/laboratoriach. Oczywiście warto wówczas zgrubnie przedstawić działanie tej techniki i sposób interpretacji wyników, uważając jednocześnie, by sumarycznie takie tłumaczenia nie zajęły istotnej części prezentacji (lepiej nie poświęcać na nie więcej niż 3 minut).

Uwagi na koniec

- Pytania dotyczące projektu warto zadawać na utworzonym na Moodlu forum – dzięki temu do odpowiedzi będą mieli od razu dostęp wszyscy uczestnicy kursu.
- Przedstawione ograniczenie górne na czas prezentacji (10 minut) z pewnością będzie egzekwowane przez prowadzących laboratoria. Warto zatem wcześniej dokonać „próbnej prezentacji” by upewnić się, że ów limit czasowy nie jest naruszony.
- Można nie mieć skrupułów przy wykorzystaniu modeli językowych przy rozwiązywaniu niniejszego zadania. Tak naprawdę jest to nawet zalecany sposób postępowania, jeśli tylko będzie towarzyszyć mu zrozumienie otrzymanego w ten sposób kodu i upewnienie się, że faktycznie realizuje on zadane polecenia.
- Zachęcamy do poświęcenia czasu na znalezienie zbioru danych, który faktycznie uznamy za potencjalne źródło ciekawej analizy. Znalezienie takiego zbioru i wymyślenie do niego ciekawych hipotez i interesujących pytań może się okazać (zwłaszcza w dobie *vibe coding*) najbardziej czasochłonną częścią projektu.